

Capítulo 8

Método de regresión discontinua

Motivación

- En Colombia hay una variedad de ejemplos de asignación de política pública con base en instrumentos de focalización:
 - El régimen subsidiado de salud.
 - Hogares Comunitarios de Bienestar.
 - Familias en Acción.

Motivación

- El Sistema de Identificación de Potenciales Beneficiarios de Programas Sociales (Sisben):
 - Es un instrumento desarrollado con el objetivo de focalizar programas de política pública hacia la población más vulnerable en Colombia y toma valores entre 0 y 100.
 - Los hogares con puntajes Sisben más bajos son más vulnerables que aquellos con puntajes más altos.

Motivación

- Familias en Acción:
 - Los beneficios están focalizados en las personas más pobres del país (familias Sisben 1).
 - El criterio de focalización para recibir beneficios es una función del puntaje Sisben.
 - Si el puntaje Sisben es inferior a 11, entonces el hogar clasifica en Sisben 1. Este umbral se eligió de una manera presumiblemente arbitraria.

Motivación

- Familias en Acción:
 - Una familia con puntaje 10.99 es prácticamente idéntica a una familia con puntaje 11.01; pero la primera familia sí participa en el programa y la segunda no.
 - La segunda familia puede utilizarse como contrafactual de la primera.


Regresión discontinua (RD): Notación

- D_i : Indicador de tratamiento.
- Y_i : Variable de resultado.
- X_i : Características observables que no dependen directamente de la variable del tratamiento; pero afectan la variable de resultado.
- Z_i : Variable observable continua de focalización que determina la elegibilidad en el programa dependiendo de si su valor es mayor o menor que un determinado umbral fijo $\bar{Z}$.

Regresión discontinua (RD)

Caso especial de diseño no experimental

Ocurre cuando



La probabilidad de participación cambia
discontinuamente con una variable continua
observada Z .

La asignación del tratamiento depende completa o
parcialmente del valor que la variable Z toma a lado y lado
de un umbral fijo.

Regresión discontinua (RD)



Los individuos a la izquierda del umbral $\bar{Z}$ participan en el programa con probabilidad 1; mientras que los individuos a la derecha no participan en el programa.

Regresión discontinua (RD)

- El estimador de RD se basa en la observación de que los individuos justamente a la izquierda del umbral deben ser muy parecidos a los individuos justamente a la derecha de éste.
- Excepto que los primeros participan en el programa y los segundos no.
- Entonces los segundos podrían ser un contrafactual válido de los primeros.

Regresión discontinua (RD)

- Supuestos:
 - El umbral es arbitrario.
 - Los determinantes de la variable de resultado, X , son muy parecidos a la izquierda y a la derecha del umbral.

Regresión discontinua (RD)

- La comparación de estos dos grupos resulta en un estimador válido del impacto del tratamiento alrededor del punto de corte.
- El parámetro estimado por RD es un efecto promedio local del tratamiento (LATE), porque se centra en los individuos en una vecindad arbitrariamente pequeña a la izquierda y a la derecha del umbral $\bar{Z}$.

Ejemplo: *Canasta*

- **Población elegible:** Hogares Sisben 1



Población cuyo puntaje Sisben es igual o inferior a un umbral $\bar{Z}$.

Un hogar con un puntaje Sisben de $\bar{Z}$ o menos puede participar en el programa.



La probabilidad de participación cambia discontinuamente.

Ejemplo: *Canasta*

Esta implementación permite la aplicación de RD:

Los determinantes de la variable de resultado, Y , exceptuando la participación en el programa, son similares para individuos con un puntaje Sisben por debajo y por encima de $\bar{Z}$.

Regresión discontinua nítida: Aspectos teóricos

- Z determina completamente, de forma determinística, la participación en el programa sobre la base de un umbral $\bar{Z}$:

$$D_i(Z_i) = I[Z_i \leq \bar{Z}]$$

donde $I[*] = 1$ si la condición $*$ se cumple, y 0 de lo contrario.

- La probabilidad de participación es discontinua en el umbral al pasar de uno (a la izquierda) a ser determinísticamente igual a cero (a la derecha).

Regresión discontinua nítida: Aspectos teóricos

- **Supuestos:**
 - Los individuos o los administradores del programa no contribuyen en la decisión de si participar o no.
 - Los individuos no pueden ajustar el valor de Z en respuesta a los criterios elegibilidad del programa.
 - Cualquier autoselección está dada sobre la base de características exógenas.

Ejemplo: *Canasta*

Si el programa *Canasta* se asignara a los hogares de Sisben 1 y la participación fuera **obligatoria**.




El puntaje Sisben determina completamente la participación en el tratamiento.



Diseño: regresión discontinua nítida (RDN)

Regresión discontinua nítida:

Aspectos teóricos



- Condición de identificación:


$$\lim_{z \downarrow \bar{Z}} D(Z = z) \neq \lim_{z \uparrow \bar{Z}} D(Z = z)$$

Derecha

Izquierda

- La principal fuente de identificación en RDN es la discontinuidad en la participación en el tratamiento en un punto específico de la distribución de Z .

Regresión discontinua nítida: Expectativas condicionales de las variables de resultado



- Las líneas sólidas corresponden a las expectativas condicionales de las variables de resultado *Y observadas*.
- Las líneas punteadas representan las expectativas condicionales de las dos variables de resultado *potenciales* para cada nivel de Z .

Regresión discontinua nítida: Expectativas condicionales de las variables de resultado

- Formalmente definimos esas expectativas condicionales como:

$$\mu_D(z) = E[Y(D)|Z = z] \quad \text{para } D = 0,1.$$

- La variable de resultado sólo se observa en presencia del tratamiento, si la variable Z está a la izquierda del umbral:
 - El individuo participa en el programa.
- La variable de resultado sólo se observa en ausencia del tratamiento, si la variable Z está a la derecha del umbral:
 - El individuo no participa en el programa.

Regresión discontinua nítida: Expectativas condicionales de las variables de resultado

La expectativa condicional de la variable de resultado *observada* está dada por la línea sólida en la gráfica.

$$\begin{aligned} E[Y|Z = z] \\ &= E[Y|D = 0, Z = z] \Pr(D = 0|Z = z) \\ &+ E[Y|D = 1, Z = z] \Pr(D = 1|Z = z) \end{aligned}$$

Relación con el método de emparejamiento

- **Se cumple:** El supuesto de independencia condicional de emparejamiento de manera trivial en RDN porque, condicional en las características observadas (en especial, Z), no hay variación en el tratamiento.
- **Se viola:** El soporte común porque no existen valores de Z para los cuales haya un traslapo de individuos tratados y no tratados.
- El supuesto de soporte común reemplaza el supuesto de que los individuos son similares alrededor del umbral.

Supuesto de continuidad local

- No existen discontinuidades en la relación entre la variable de resultado, Y , y las variables X que la determinan en $\bar{Z}$. X puede contener variables observadas y no observadas. Incluso incluye la participación en otros programas diferentes al evaluado.
- Los individuos de un lado del umbral son similares a los individuos del otro lado del umbral. Formalmente:

$$\lim_{z \downarrow \bar{Z}} E[Y(0)|Z = z] = \lim_{z \uparrow \bar{Z}} E[Y(0)|Z = z]$$

$$\lim_{z \downarrow \bar{Z}} E[Y(1)|Z = z] = \lim_{z \uparrow \bar{Z}} E[Y(1)|Z = z]$$

Regresión discontinua nítida: Análisis gráfico


- El análisis gráfico es un componente central al hacer una evaluación a través del método de regresión discontinua.
- **Es importante observar:**
 - El impacto del programa alrededor del umbral o puntaje de corte.
 - Variables observables como función del instrumento de focalización que deben ser continuas localmente.
 - Densidad del instrumento de focalización Z .

Análisis gráfico:


Supuesto de continuidad local:

Salto en variables observables en el umbral

Panel a. Continuidad



Panel b. Discontinuidad




El investigador debe proveer evidencia estadística que muestre que no hay saltos en las variables observadas alrededor del umbral $\bar{Z}_i$; por lo tanto, es válido asumir que el grupo a la izquierda del umbral es comparable con el grupo a la derecha del umbral.

Análisis gráfico:


Supuesto de no manipulación

Densidad del instrumento de focalización Z

Caso de no manipulación



Caso de manipulación



El investigador debe demostrar que el instrumento de focalización no ha sido manipulado. Si la función de densidad de probabilidad de Z tiene un salto peculiar justamente en el umbral $\bar{Z}_i$ entonces eso sería evidencia de manipulación e invalidaría el diseño RD.

Regresión discontinua nítida: Variable de resultado

- Corresponde al caso en que la probabilidad de participación cambia exactamente de uno a cero a uno y otro lado del punto de corte.
- La variable de resultado se puede escribir como:

$$Y_i = \beta_0 + \tau_i D_i + u_i$$

Por lo tanto, el supuesto de continuidad de $E[Y_i|Z_i]$ en Z es equivalente a suponer que $E[u_i|Z_i]$ y $E[\tau_i|Z_i]$ son ambas continuas en Z .

Regresión discontinua nítida: Estimador del efecto del programa

- En suma se ha establecido que los grupos comparables están en una vecindad arbitrariamente pequeña a la derecha y a la izquierda del umbral porque esos son los dos grupos más comparables. En la vecindad a la izquierda de $\bar{Z}$ se ubica el grupo de tratamiento y en la vecindad a la derecha de $\bar{Z}$ se ubica el grupo de control.
- Así, el efecto del programa será simplemente el valor promedio de la variable de resultado de los tratados (izq.) menos el valor promedio de la variable de resultado de los controles (der.):

Regresión discontinua nítida: Estimador del efecto del programa

$$\tau_{RDN}(\bar{Z}) = \lim_{z \downarrow \bar{Z}} E[Y_i | Z_i = z] - \lim_{z \uparrow \bar{Z}} E[Y_i | Z_i = z]$$

El valor promedio de la variable de resultado en una vecindad arbitrariamente pequeña a la izquierda del umbral menos el valor promedio de la variable de resultado en una vecindad arbitrariamente pequeña a la derecha del umbral.

- Siempre que se cumplan:
 - Condición de identificación.
 - Supuesto de continuidad local.


Regresión discontinua nítida: Efecto del programa

- El diseño RD identifica el efecto promedio del tratamiento para individuos cercanos al punto de discontinuidad.
- En particular, mide el impacto del tratamiento sobre un individuo seleccionado aleatoriamente con características observables $Z_i = \bar{Z}$.
 - Es un estimador del impacto *local* del programa.
- En esta medida, existe una tensión entre la validez interna y la validez externa de la evaluación.

Regresión discontinua borrosa: Aspectos teóricos

- En este caso, la participación efectiva en el programa depende de:
 - Variable observable continua de focalización Z .
 - Otras dimensiones observadas y no observadas de los individuos. En últimas, no todos los individuos a la izquierda participan, y algunos individuos a la derecha del umbral también participan.
- La probabilidad de participación cambia discontinuamente en el punto $\bar{Z}$.

Regresión discontinua borrosa: Aspectos teóricos




La probabilidad de recibir el tratamiento es positiva tanto a la izquierda como a la derecha de $\bar{Z}$, pero hay un cambio discreto en esa probabilidad justo en el umbral.

Regresión discontinua borrosa (RDB): Aspectos teóricos

- Condición de identificación:

$$\lim_{z \downarrow \bar{Z}} Pr(D = 1 | Z = z) \neq \lim_{z \uparrow \bar{Z}} Pr(D = 1 | Z = z)$$

- La principal fuente de identificación en RDB es la discontinuidad en la probabilidad de participación en el tratamiento en un punto específico de la distribución de Z .



Ejemplo 1: *Canasta*

Población elegible: Hogares Sisben 1, PERO los individuos deben decidir si hacen la solicitud o no.

El umbral $\bar{Z}$

No es obligatorio.

→ Determina parcialmente la participación en el programa.

La probabilidad de participación

→ Si $Z_i \leq \bar{Z}$, entonces la probabilidad de participación es mayor o igual a cero.

→ Si $Z_i \geq \bar{Z}$, entonces la probabilidad de participación es cero.

Ejemplo 2: *Canasta*

- Población elegible:** Hogares de Sisben 1 y 2.
- └ Cobertura universal para Sisben 1.
 - Mercado para todos los hogares.
 - └ Cobertura parcial para Sisben 2.
 - Mercado para 100,000 hogares aleatoriamente escogidos.

La probabilidad de participación

- └ Puede ser mayor a cero tanto a la izquierda como a la derecha de $\bar{z}$.

Ejemplo 2: *Canasta*


Bajo este diseño:

Hay individuos participantes a ambos lados del umbral $\bar{Z}$.

Debido a que la cobertura es parcial para Sisben 2, la probabilidad cambia discretamente en el punto de corte $\bar{Z}$.

→ La probabilidad cambia discretamente en el punto de corte $\bar{Z}$, porque para Sisben 2 es más improbable participar en el programa dado que tienen un número restringido de cupos.

Regresión discontinua borrosa: Expectativas condicionales de las variables de resultado



La expectativa condicional de la variable de resultado *observada* está dada por la línea sólida en la gráfica.

Regresión discontinua borrosa: Expectativas condicionales de las variables de resultado

Expectativa condicional observada:

$$E[Y|Z = z] = E[Y(0)|D = 0, Z = z] \Pr(D = 0|Z = z) + \\ E[Y(1)|D = 1, Z = z] \Pr(D = 1|Z = z)$$

En este caso **no** es necesariamente cierto que:

$$E[Y(z)|D = d, Z = z] = E[Y(z)|Z = z]$$



Porque Z sólo determina parcialmente el tratamiento.

Regresión discontinua borrosa: Análisis gráfico

- El análisis gráfico es un componente central al hacer una evaluación a través del método de RDB, al igual que lo es en RDN.
- Es importante observar:
 - El impacto del programa alrededor del umbral o puntaje de corte.
 - Variable observables como función del instrumento de focalización para comprobar el supuesto de continuidad local.
 - Densidad del instrumento de focalización Z .

Regresión discontinua borrosa: Estimador del efecto del programa

- Ahora en el caso de RDB, el salto de Y en el umbral ya no estima el impacto del programa, porque no todos los de la izquierda participan y no todos los de la derecha no participan.
- En este caso, el salto en Y en el umbral estima el impacto de la *elegibilidad* de participar, porque el umbral determina la elegibilidad; pero no establece completamente la participación.
- Es necesario tener en cuenta el cambio discreto en la probabilidad de participar en el programa en el umbral.

Regresión discontinua borrosa: Estimador del efecto del programa

- El efecto del programa es el salto en Y en el umbral ponderado por el salto en la probabilidad de participación en el umbral.

$$\begin{aligned}\tau_{RDN}(\bar{Z}) &= E(\tau_i | D_i = 1, Z \geq \bar{Z}) \\ &= \frac{\lim_{z \downarrow \bar{Z}} E[Y_i | Z_i = z] - \lim_{z \uparrow \bar{Z}} E[Y_i | Z_i = z]}{\lim_{z \downarrow \bar{Z}} \Pr(D = 1 | Z = z) - \lim_{z \uparrow \bar{Z}} \Pr(D = 1 | Z = z)}\end{aligned}$$

- Siempre que:
 - No existan externalidades del programa.
 - Se cumpla la condición de identificación.
 - Se cumpla el supuesto de continuidad local.

Regresión discontinua borrosa: Estimador del efecto del programa

El efecto del programa es:

$$\tau_{RDN}(\bar{Z}) = E(\tau_i | D_i = 1, Z \geq \bar{Z})$$

$$\tau_{RDB}(\bar{Z}) = \frac{\lim_{z \downarrow \bar{Z}} E[Y_i | Z_i = z] - \lim_{z \uparrow \bar{Z}} E[Y_i | Z_i = z]}{\lim_{z \downarrow \bar{Z}} Pr(D = 1 | Z = z) - \lim_{z \uparrow \bar{Z}} Pr(D = 1 | Z = z)}$$

← Covarianza entre Y & Z
← Covarianza entre D & Z



Es decir, coincide exactamente con el **estimador de Wald** que estudiamos en el capítulo de “variables instrumentales”. El numerador tiene la covarianza entre la variable de resultado y el instrumento, y el denominador tiene la covarianza entre la variable endógena (participación) y el instrumento.

Regresión discontinua borrosa: Efecto del programa

- El estimador de regresión discontinua borrosa coincide con el estimador de Wald para variables instrumentales.
 - Se debe interpretar como efecto local.
- Hann, Todd y van der Klaaw (2001) utilizan el supuesto de monotonicidad local, que es un supuesto más fuerte, según el cual los individuos a cada lado del umbral son idénticos en variables observadas y en variables no observadas.
 - Se interpreta como efecto local promedio.

Ejemplo 1: Canasta

- **Población elegible:** Sólo hogares Sisben 1, PERO los individuos deben decidir si hacen la solicitud o no (no es obligatorio).
- Sólo los individuos con puntaje Sisben menor al umbral pueden participar con probabilidad positiva.

- El efecto del programa en este caso particular es:

$$\frac{\lim_{z \uparrow \bar{Z}} E[Y_i | Z_i = z] - \lim_{z \downarrow \bar{Z}} E[Y_i | Z_i = z]}{\lim_{z \uparrow \bar{Z}} Pr(D = 1 | Z = z) - 0}$$

Regresión discontinua borrosa: Análogo muestral

$$\hat{\tau}_{RDB}(\bar{Z}) = \frac{\bar{Y}(\bar{Z}^+) - \bar{Y}(\bar{Z}^-)}{\widehat{Pr}(D = 1|\bar{Z}^+) - \widehat{Pr}(D = 1|\bar{Z}^-)}$$

- **Donde:**

$\bar{Y}(\bar{Z}^-)$

$\bar{Y}(\bar{Z}^+)$



Promedios muestrales de la variable de resultado a la izquierda y a la derecha del umbral, respectivamente.

$\widehat{Pr}(D = 1|\bar{Z}^-)$

$\widehat{Pr}(D = 1|\bar{Z}^+)$



Estimadores de probabilidad de participación a la izquierda y a la derecha del umbral, respectivamente.

Implementación empírica

$$\bar{Y}(\bar{Z}^-)$$

$$\bar{Y}(\bar{Z}^+)$$

Los simples promedios a la izquierda y derecha del umbral corresponden a las líneas horizontales, el salto entre los dos estaría dado por el segmento b-c. Si, en cambio, ajustamos una regresión lineal a los datos en la vecindad izquierda y derecha del umbral (línea sólida en negrilla), entonces el salto en el umbral estaría dado por el segmento a-d. El último se ajusta más al verdadero salto, que el primero.

Implementación empírica

- Se puede utilizar un método de estimación:
 - Paramétrico .
 - Semiparamétrico.
 - No paramétrico.
- El efecto de regresión discontinua requiere la estimación de puntos límite alrededor del umbral de las funciones de expectativa condicional.

Implementación empírica: Estimación paramétrica de RDN

- El efecto del programa puede estimarse por medio de:

$$Y_i = m(Z_i) + \beta_1 D_i + e_i$$

Donde :

$$e_i = Y_i - E[Y_i | D_i, Z_i]$$

$$m(Z) = E[u_i | Z] + (E[\tau_i | Z] - E[\tau_i | \bar{Z}]) D_i$$

Por el supuesto de continuidad local es una función continua de Z en el umbral $\bar{Z}$

- β_1 : Efecto promedio del tratamiento en $\bar{Z}$.

Implementación empírica: Estimación paramétrica de RDN

- El efecto del programa puede estimarse por medio de:

$$Y_i = m(Z_i) + \beta_1 E[D_i|Z_i] + \omega_i$$

Donde :

$m(Z)$: Es una función continua de z en $\bar{Z}$.

$E[D_i|Z_i]$: Es discontinuo en el umbral.

β_1 : Efecto promedio del tratamiento en el umbral o el efecto local promedio dependiendo del supuesto adaptado.

Implementación empírica: Estimación paramétrica de RDB

- Estimación en dos etapas:

- Primera etapa → Probabilidad de participación

$$D_i = E[D_i|Z_i] + v_i = f(Z_i) + \gamma I[Z_i \geq \bar{Z}] + v_i$$

γ : Mide la discontinuidad de la probabilidad de participación en $\bar{Z}$.

Implementación empírica: Estimación paramétrica de RDB

- Estimación en dos etapas:
 - Segunda etapa:

$$Y_i = m(Z_i) + \beta_1 E[D_i|Z_i] + \omega_i$$

Donde se reemplaza $E[D_i|Z_i]$ por $\widehat{Pr}(D = 1|Z_i)$ predicho con base en los estimadores de la primera etapa (note similitud con el método de variables instrumentales por MC2E).

- $f(\cdot)$ y $m(\cdot)$ pueden ser funciones polinómicas o funciones *spline* de z .

Estimación no paramétrica o semiparamétrica

- Reduce el sesgo asociado a error de especificación en $f(\cdot)$ y $m(\cdot)$.
- Estimación no paramétrica:
 - Regresión no paramétrica de Y sobre Z a cada lado del punto de discontinuidad.
 - Regresión no paramétrica de D sobre Z a cada lado del punto de discontinuidad.

Estimación no paramétrica

Ancho de banda (h)

- **Ancho de banda** es la ventana de observaciones que define la vecindad arbitrariamente pequeña a cada lado del umbral.
- **Ventajas de un ancho de banda más amplio:**
 - Mayor número de observaciones.
 - Estimadores más eficientes.
 - Disminuye la varianza.
- **Desventajas de un ancho de banda más amplio:**
 - Individuos más alejados del umbral pueden ser muy distintos de los individuos cercanos a éste.
 - El grupo de control puede resultar muy heterogéneo y, por lo tanto, no comparable con el grupo de tratamiento.
 - Aumenta el sesgo.

Estimación no paramétrica

- Métodos más populares en RD:
 - Estimador de Kernel.
 - Estimador de regresión lineal.
 - Regresión polinomial local.
 - Estimador de modelo lineal parcial.

Estimación no paramétrica

Estimador de Kernel

$$\hat{\tau}_{RDB}(\bar{Z}) = \frac{\bar{Y}(\bar{Z}^+) - \bar{Y}(\bar{Z}^-)}{\widehat{Pr}(D = 1|\bar{Z}^+) - \widehat{Pr}(D = 1|\bar{Z}^-)}$$

- Donde:

$$\bar{Y}(\bar{Z}^+) = \frac{\sum_i Y_i I[Z_i \geq \bar{Z}] K\left(\frac{Z_i - \bar{Z}}{h}\right)}{\sum_i I[Z_i \geq \bar{Z}] K\left(\frac{Z_i - \bar{Z}}{h}\right)}$$

$$\bar{Y}(\bar{Z}^-) = \frac{\sum_i Y_i I[Z_i < \bar{Z}] K\left(\frac{Z_i - \bar{Z}}{h}\right)}{\sum_i I[Z_i < \bar{Z}] K\left(\frac{Z_i - \bar{Z}}{h}\right)}$$

Promedio ponderado de la variable de resultado en una vecindad de distancia h , a cada lado del punto de discontinuidad.

Estimación no paramétrica

Estimador de Kernel

$$\widehat{Pr}(D = 1|\bar{Z}^+) = \frac{\sum_i D_i I[Z_i \geq \bar{Z}] K\left(\frac{Z_i - \bar{Z}}{h}\right)}{\sum_i I[Z_i \geq \bar{Z}] K\left(\frac{Z_i - \bar{Z}}{h}\right)}$$

$$\widehat{Pr}(D = 1|\bar{Z}^-) = \frac{\sum_i D_i I[Z_i < \bar{Z}] K\left(\frac{Z_i - \bar{Z}}{h}\right)}{\sum_i I[Z_i < \bar{Z}] K\left(\frac{Z_i - \bar{Z}}{h}\right)}$$

Probabilidad de
participación a cada lado
del umbral.

- $K(\cdot)$: Función Kernel (que pesa la observación i dependiendo de qué tan lejos está del umbral).
- h : Ancho de banda
- $I(*)$: $1 \rightarrow$ Si la condición $(*)$ se cumple
 $0 \rightarrow$ De lo contrario

Estimación no paramétrica

Regresión lineal local

- La regresión lineal local tiene mejor desempeño en los límites que la función Kernel.

$$\min_{\alpha_1, \beta_1} \sum_{i | \bar{Z} - h < Z_i < \bar{Z}} (Y_i - \alpha_1 - \beta_1(Z_i - \bar{Z}))^2 \quad \left. \vphantom{\min_{\alpha_1, \beta_1}} \right\} \text{Regresión lineal local a la izquierda del umbral.}$$

$$\min_{\alpha_2, \beta_2} \sum_{i | \bar{Z} < Z_i < \bar{Z} + h} (Y_i - \alpha_2 - \beta_2(Z_i - \bar{Z}))^2 \quad \left. \vphantom{\min_{\alpha_2, \beta_2}} \right\} \text{Regresión lineal local a la derecha del umbral.}$$

Estimación no paramétrica

Regresión lineal local

- Los estimadores de los límites en la variable de resultado estarían dados por:

$$\begin{aligned}\bar{Y}(Z^-) &= \hat{\alpha}_1 + \hat{\beta}_1(\bar{Z} - \bar{Z}) = \hat{\alpha}_1 \\ \bar{Y}(Z^+) &= \hat{\alpha}_2 + \hat{\beta}_2(\bar{Z} - \bar{Z}) = \hat{\alpha}_2\end{aligned}$$

- El estimador del efecto del tratamiento en RDN sería el salto:

$$\hat{\tau}_{RD}(\bar{Z}) = \hat{\alpha}_2 - \hat{\alpha}_1$$

- El resultado depende de la validez del supuesto de continuidad local.

Estimación no paramétrica

Regresión lineal local

- **Supuesto de continuidad local:**
Para establecer la validez de este supuesto es necesario:
 - Comparar las características observadas promedio de los individuos en una vecindad arbitrariamente pequeña del umbral a cada lado.
 - Evaluar la sensibilidad del estimador de RD a la inclusión de variables observadas adicionales.
 - Datos panel: Estimador de RD con datos del período de línea base.

Implementación del diseño de RD en Stata

- Metodologías:
 - Imbens y Lemieux (2007).
 - Imbens y Lemieux con peso tipo triangular.
 - Modificación de Imbens y Lemieux con pesos tipo triangular.
 - Rutina “rd” (Nichols, 2007).

Implementación del diseño de RD

Ejemplo 2: *Canasta*

- Población elegible:** Hogares de Sisben 1 y 2.
- └ Cobertura universal para Sisben 1.
 - Mercado para todos los hogares.
 - └ Cobertura parcial para Sisben 2.
 - Mercado para 100,000 hogares escogidos al azar.

La probabilidad de participación

- └ Mayor o igual a cero tanto a la izquierda como a la derecha de **10**.

Implementación del diseño de RD

Ejemplo 2: *Canasta*

Bajo este diseño:

Hay individuos participantes a ambos lados del umbral **10**.

Debido a que la cobertura es parcial para Sisben 2, la probabilidad cambia discretamente en el punto de corte 10.

El ejemplo se refiere a un caso de regresión discontinua borrosa.

Implementación del diseño de RD: Imbens y Lemieux (2007)

1. Definir el ancho de banda.
2. Estimar dos regresiones, una a cada lado del umbral.
3. Calcular la predicción de la variable de resultado, Y , condicional en el puntaje Sisben a cada lado del umbral con base en esas regresiones.
4. Estimar el salto de la variable de resultado en el punto de discontinuidad.
5. Mismo procedimiento para la probabilidad de participación en el programa.
6. El efecto del programa es el cociente entre el salto en Y y el salto en la probabilidad de participación en el umbral.

Implementación del diseño de RD: Imbens y Lemieux (2007)

- Formalmente:

$$(\hat{\alpha}_l, \hat{\beta}_l) = \arg \min_{\alpha, \beta} \sum_{i|10-h < \text{SISBEN}_i < 10} (Y_i - \alpha - \beta(\text{SISBEN}_i - 10))^2$$

Regresión de Y sobre el instrumento de focalización normalizado en el umbral $\bar{Z}$, con observaciones a la izquierda únicamente. Luego repite a la derecha.

- α_l : Intercepto $\rightarrow$ Estimador de Y al acercarse al umbral por la izquierda.
- β_l : Pendiente de la regresión.

Implementación del diseño de RD: Imbens y Lemieux (2007)

Talla del niño según la edad

- De manera análoga, α_r y β_r : Intercepto y pendiente al acercarse al umbral por la derecha.
- α_l : Estimador de Y al acercarse al umbral por la izquierda.

Implementación del diseño de RD: Imbens y Lemieux (2007)

Estimador del efecto por regresión discontinua nítida:

$$\hat{\tau}_y(\bar{Z}) = \hat{\alpha}_l - \hat{\alpha}_r$$

Implementación del diseño de RD: Imbens y Lemieux (2007)

- **Estimador del efecto en regresión discontinua borrosa:**
 - Es necesario estimar también la probabilidad de participación en el tratamiento a ambos lados del punto de discontinuidad:

$$(\widehat{\alpha}_r, \widehat{\beta}_r) = \arg \min_{\alpha, \beta} \sum_{i|10 \leq \text{SISBEN}_i < 10+h} (Y_i - \alpha - \beta(\text{SISBEN}_i - 10))^2$$

Regresión de D sobre el instrumento de focalización normalizado en el umbral $\bar{Z}$, con observaciones a la izquierda únicamente. Luego repite a la derecha.

El estimador del impacto por RDB estaría dado por:


$$\hat{\tau}(\bar{Z}) = \frac{\hat{\tau}_y}{\hat{\tau}_d} = \frac{\widehat{\alpha}_l - \widehat{\alpha}_r}{\widehat{\alpha}_{dl} - \widehat{\alpha}_{dr}}$$

Implementación del diseño de RD: Imbens y Lemieux con peso tipo triangular

- Define un ancho de banda.
- En las estimaciones de los promedios a cada lado del umbral se les da ahora más peso a las observaciones más cercanas al umbral y menos peso a las observaciones más lejanas de éste, en vez de pesarlas todas igual.

Implementación del diseño de RD: Imbens y Lemieux con peso tipo triangular

Pesos de tipo "triangular"



- Los pesos de cada observación se calculan de acuerdo con:

$$k(Z_i) = \begin{cases} 1 - \frac{|Z_i - \bar{Z}|}{h} & \text{si } |Z_i - \bar{Z}| < h \\ 0 & \text{caso contrario} \end{cases}$$

Con lo cual, entre más cercana está la observación al umbral tiene un mayor peso $k(Z_i)$ en la regresión, y viceversa.

Implementación del diseño de RD: Modificación de Imbens y Lemieux con pesos tipo triangular

- Define un ancho de banda.
- Hace una única regresión utilizando todas las observaciones a la derecha y a la izquierda del umbral.

$$Y_i = \beta_0 + \beta_1 W_i + \beta_2 (SISBEN - 10)_i + \beta_3 ((SISBEN - 10)_i * W_i) + \varepsilon_i$$

- Donde W es un indicador de elegibilidad

$$W_i = \begin{cases} 1 & \text{si } SISBEN_i < 10 \\ 0 & \text{caso contrario} \end{cases}$$

Implementación del diseño de RD: Modificación de Imbens y Lemieux peso triangular

Implementación del diseño de RD: Modificación de Imbens y Lemieux peso triangular

- El intercepto a la izquierda del umbral estaría dado por:

$$E[Y_i|W_i = 1, Z_i = \bar{Z}] = \beta_0 + \beta_1 W_i + \beta_2 (Z_i - \bar{Z}) + \beta_3 ((Z_i - \bar{Z}) * W_i)$$

$$E[Y_i|W_i = 1, Z_i = \bar{Z}] = \beta_0 + \beta_1(1) + \beta_2(0) + \beta_3((0) * 1)$$

$$E[Y_i|W_i = 1, Z_i = \bar{Z}] = \beta_0 + \beta_1$$

Implementación del diseño de RD: Modificación de Imbens y Lemieux peso triangular

- De manera análoga, el intercepto a la derecha del umbral estaría dado por β_0 .
- Entonces el salto en la discontinuidad está dado por la diferencia entre uno y otro (izquierda-derecha) = $\beta_1 \rightarrow$ Indica el valor de la discontinuidad para la variable de resultado y corresponde al efecto del tratamiento en regresión discontinua nítida.

Implementación del diseño de RD: Modificación de Imbens y Lemieux peso triangular

- En regresión discontinua borrosa es necesario calcular también el salto en la probabilidad de participación:

$$Pr(D_i = 1) = \gamma_0 + \gamma_1 W_i + \gamma_2 (SISBEN - 10)_i + \gamma_3 ((SISBEN - 10)_i * W_i) + \varepsilon_i$$

- El estimador del impacto del programa sería entonces:

$$\hat{\tau} = \frac{\hat{\tau}_y}{\hat{\tau}_d} = \frac{\hat{\beta}_1}{\hat{\gamma}_1}$$

Implementación del diseño de RD

En esencia, el estimador de RDB corresponde al mismo estimador de Wald que se puede obtener por mínimos cuadrados en dos etapas:

$$\tau_{RDB}(\bar{Z}) = \frac{\lim_{z \uparrow \bar{Z}} E[Y_i | Z_i = z] - \lim_{z \downarrow \bar{Z}} E[Y_i | Z_i = z]}{\lim_{z \uparrow \bar{Z}} Pr(D = 1 | Z = z) - \lim_{z \downarrow \bar{Z}} Pr(D = 1 | Z = z)}$$

Así, se estimaría por mínimos cuadrados en dos etapas en la submuestra de observaciones tal que $\bar{Z} - h \leq Z_i \leq \bar{Z} + h$.

En particular: utilizaría W como el instrumento (o restricción de exclusión) y D como la variable explicativa endógena. Es decir, se estima la primera etapa de D sobre W , se construye la predicción de D con base en los estimadores de la primera etapa y, finalmente, se estima una regresión de Y sobre $\hat{D}$. De este procedimiento se obtienen el estimador del efecto y su varianza.

Selección del ancho de banda

- Validación cruzada:
 1. Estimar el impacto por RD para cada posible valor de ancho de banda.
 2. Escoger el valor para el cual se minimice el error de predicción en la variable de resultado y en la probabilidad de participación en el tratamiento.

Selección del ancho de banda

- Validación cruzada:

El ancho de banda óptimo es el mínimo entre el h que minimiza el error de predicción de la variable de resultado, Y , y el que minimiza el error de predicción de la probabilidad de participación en el programa.

$$C_Y(h) = \frac{1}{N} \sum_{i=1}^N (Y_i - \hat{\mu}(Z_i, h))^2$$

$$\hat{\mu}(Z_i, h) = \hat{\mu}(SISBEN_i, h) = \begin{cases} \hat{\alpha}_l(h) & \text{si } SISBEN_i < 10 \\ \hat{\alpha}_r(h) & \text{si } SISBEN_i \geq 10 \end{cases}$$

Ventaja y desventajas

VENTAJA	DESVENTAJAS
Los supuestos para implementarlo son plausibles en la mayoría de los casos, lo cual produce estimadores del impacto del programa creíbles.	• El hecho de que el estimador local, se estime sólo alrededor del punto de discontinuidad $\bar{Z}$. Esto tiene implicaciones en términos del alcance de la interpretación del estimador. • Requiere muestras grandes para lograr densidad a lado y lado del umbral.

Ejemplo:

Régimen subsidiado de salud y los recién nacidos (Camacho y Conover, 2009)


Objetivo: Establecer si la implementación del régimen subsidiado de salud tuvo efectos positivos en la salud de los niños recién nacidos en Colombia.

Selección: Para pertenecer al régimen subsidiado se debe ser clasificado como pobre a través de la encuesta Sisben, es decir, obtener un puntaje menor a 47.

Ejemplo:

Régimen subsidiado de salud y los recién nacidos (Camacho y Conover, 2009)

Probabilidad de pertenecer al régimen subsidiado



Ejemplo:

Régimen subsidiado de salud y los recién nacidos (Camacho y Conover, 2009)

Diseño de la evaluación: Regresión discontinua borrosa.



Existen
individuos

- Con puntajes > 47 → No pertenecen al régimen subsidiado.
- Con puntajes < 47 → Pertenecen al régimen subsidiado.

Ejemplo:

Régimen subsidiado de salud y los recién nacidos (Camacho y Conover, 2009)

Variables de interés:

Variables de acceso a servicios de salud para madres embarazadas:

- Visitas prenatales.
- Si el niño nació en un hospital.
- Si contó con la presencia de un médico en el momento del nacimiento.

Estado de salud en niños recién nacidos:

- Peso en el momento del nacimiento.

Ejemplo:

Régimen subsidiado de salud y los recién nacidos (Camacho y Conover, 2009)

Se crean una serie de variables dicótomas para:

Peso al nacer:

- Si el recién nacido se considera de bajo peso.
- Si el recién nacido se considera de muy bajo peso.
- Si el nacimiento fue prematuro.
- Si la prueba Apgar a los cinco minutos del nacimiento es superior a siete.

Ejemplo:

Régimen subsidiado de salud y los recién nacidos (Camacho y Conover, 2009)

Metodología:

1. Instrumentar la participación en el régimen subsidiado de salud utilizando el criterio de elegibilidad para el régimen.

Variable dicótoma:
$$\begin{cases} 1 & \text{si puntaje Sisben} \leq 47 \\ 0 & \text{de lo contrario} \end{cases}$$

2. Se estiman diferentes modelos en la primera etapa de la regresión, con diferentes anchos de banda y la inclusión de diferentes controles.

Ejemplo:

Régimen subsidiado de salud y los recién nacidos (Camacho y Conover, 2009)

Se prueba que no existen discontinuidades en una serie de variables observadas de control.


Resultados:

Encuentran que el régimen subsidiado tiene un impacto significativo en la incidencia del bajo peso al nacer.

Se encuentra que una expansión del 10% en el régimen subsidiado de salud reduce la incidencia de nacimientos de bajo peso entre 1.3% y 3.7%.

Ejemplo:

Régimen subsidiado de salud y los recién nacidos (Camacho y Conover, 2009)



Ejemplo:

Régimen subsidiado de salud y los recién nacidos (Camacho y Conover, 2009)

Pese a que se encuentra un impacto significativo en la incidencia bajo peso al nacer, no hay ningún impacto significativo en el acceso a los servicios de salud por parte de madres embarazadas.

Conclusiones

- Importancia del análisis gráfico:
 - El impacto del programa alrededor del umbral o puntaje de corte.
 - Variables observables como función del instrumento de focalización.
 - Densidad del instrumento de focalización Z .

Conclusiones

- Intervalos para análisis gráfico:
 - Suficientemente amplios:
 - Contener suficientes observaciones.
 - Ser precisos.
 - Suficientemente pequeños:
 - Observar saltos en el punto de discontinuidad.

Conclusiones

- Selección del intervalo de confianza óptimo a partir del método de validación cruzada.
- Pruebas de especificación:
 - Densidad de la variable de focalización.
 - Impacto utilizando diferentes anchos de banda.
 - Pruebas contrafactuales de impactos donde a priori no debería haber efectos del programa.