

EDA for Business Analytics

Using python.

Iván Andrés Trujillo

ivantrujillo1229

ai-page.readthedocs.io

El objetivo de esta clase es mostrarles la importancia del EDA y darle un alcance fuera del Machine learning.

...

Hoy no les voy a enseñar como calcular una media o una desviación estándar. Les voy a mostrar cómo esos conceptos pueden terminar cambiando nuestra arquitectura.

Problema

Un banco quiere minimizar el costo de operación del servidor que procesa solicitudes de crédito.

Cuando llegan más de 20 solicitudes entonces, se forma una cola y:

- Necesidad de activar capacidad adicional
- Pérdida de usuario
-

Decisión

Se debe contratar o no servicio de autoscaling?

...

El costo de una solicitud es:

$$C = C_0 \max(X - 15, 0) \quad (1)$$

dónde C_0 es el costo de no procesar inmediatamente una solicitud.
Para este ejercicio suponemos que $C_0 = \$100,000$.

Autoscaling

30 mil por hora, independiente del número de solicitudes

La data

	solicitud_id	fecha_hora
0	SOL000005	2026-08-01 00:04:20
1	SOL000002	2026-08-01 00:37:17
2	SOL000004	2026-08-01 00:37:27
3	SOL000001	2026-08-01 00:40:20
4	SOL000003	2026-08-01 00:49:18

Data - csv

(click aquí)

Son conteos

Pues como son conteos uso **poisson** para responder la pregunta:

...

$$P(X > 10) \quad (2)$$

pero como hago para usar la información de la data y responder esta pregunta?

...

Usando el concepto de máxima verosimilitud? que en síntesis es simplemente encontrar el parámetro que maximice la probabilidad de observar los datos!

...

En poisson simplemente es:

$$\hat{\lambda}_{MLE} = \frac{1}{n} \sum x_i \quad (3)$$

$$\hat{\lambda}_{MLE} \approx 10 \quad (4)$$

ahora que pusimos que $X \sim \text{Poisson}(\lambda)$ y calculamos el parámetro entonces:

$$P(X > 15) \approx 0.05 \quad (5)$$

$$\hat{\lambda}_{MLE} \approx 10 \quad (4)$$

ahora que pusimos que $X \sim \text{Poisson}(\lambda)$ y calculamos el parámetro entonces:

$$P(X > 15) \approx 0.05 \quad (5)$$

Important Warning

Estamos perdiendo (por costo de oportunidad) aprox. 34 millones mensuales.

Nos faltó el EDA!

No solo es presentar datos por presentar, es entender la naturaleza de los datos,

$$E[x] = \lambda \quad (6)$$

$$\text{var}(X) = \lambda \quad (7)$$

si hubiésemos hecho un EDA nos daríamos cuenta que presentamos sobredispersión:

	Métrica	Valor
0	Media	10.060000
1	Varianza	31.750000
2	Índice de dispersión	3.160000

	Modelo	Costo esperado/hora	Decisión
0	Poisson	10831.625210	No usar autoscaling
1	Binomial Negativa	77339.742554	Usar autoscaling

	Modelo	p-value	Conclusión ($=0.05$)
0	Poisson	0.000000	Se rechaza H_0
1	Binomial Negativa	0.588191	No se rechaza H_0

...

(click aquí)