

Introducción a supervivencia

Iván Andrés Trujillo

ivantrujillo1229@gmail.com

ai-page.readthedocs.io

introducción

En el análisis de supervivencia se pretende establecer una función que:

$$S(t) = \text{prob}(T > t)$$

Nos indique con que probabilidad aún no ha ocurrido un evento en el periodo determinado t . Aunque históricamente se asocia con la determinación del evento de defunción no es necesario que este sea el evento de interés, se extiende a todo evento que se presente en un lapso determinado de tiempo.

Sean las variables aleatorias no-negativas $t_1, t_2, \dots, t_n$ que representan el tiempo hasta la ocurrencia de un evento de interés entonces definimos:

$$f(t) \tag{1}$$

$$F(t) = P(T \leq t) \tag{2}$$

$$S(t) = 1 - F(T) = P(T > t) \tag{3}$$

definición

La función de supervivencia indica la probabilidad de que el evento de interés no haya ocurrido aún en el tiempo t .

Estudios de supervivencia

algunos ejemplos son;

- Tiempo transcurrido desde el diagnóstico de cáncer de estómago hasta el fallecimiento del individuo.
- Tiempo que transcurre desde la suscripción hasta el churn en una línea de telefonía móvil.
- Tiempo transcurrido desde el inicio de tratamiento hasta la recuperación del movimiento de individuos afectados con Guillain- Barré.
- Tiempo desde el desembolso de un crédito hasta que un individuo incurra en su primer mora.

Variables de estudio

En un análisis básico (descriptivo) solo necesitamos la variable de ocurrencia del evento (si se presenta o no) y el tiempo de observación, este ultimo depende del inicio de intervención o tratamiento hasta el cierre del control.

Ejemplo de una base de datos pero y el ¿Estado 2?

caso	estado	tiempo en meses
1	1	24
2	1	14
3	0	60
4	1	17
5	2	38
6	1	20
7	0	48
8	1	9
9	1	1
10	0	10

Table: Base de datos

En la estimación básica de supervivencia solamente se puede presentar el evento una vez, es decir si un individuo presenta el evento, termina su seguimiento; no puede volver a presentar el evento. Aunque todas las observaciones se tomaron de esta forma existe un concepto que hay que tener en cuenta, el de **censura**.

La censura

la censura se presenta por varias razones; entre ellas está por que al terminar el periodo de estudio el individuo no presentó el evento de interés o no se pudo establecer cual fue su resultado (desenlace) o si se dió por otras razones que desconocemos, por lo tanto son observaciones censuradas:

- al finar los 3 años de seguimiento por diagnostico de cáncer de estomago el individuo sigue vivo.
- se censuró porque presentó un evento que limitó su seguimiento.
- se trato de cáncer de mama pero murió de un accidente de tránsito.
- el individuo cambió su lugar de residencia y perdimos su control.

La censura aporta información

...
el tipo de censura que nos interesa se denomina **censura por la derecha** lo que implica que hay otros tipos de censura.

Aunque no conozcamos el resultado final del individuo (o el evento de interés no se presentó) nos aporta información debido a que contribuye a la población susceptible en el periodo antes de su censura.

Censura

la variable *estado* de modo que 0 fallecido por cáncer (objeto de estudio) ; 1 vivo ; 2 perdido.

caso	estado	tiempo en meses
1	1	24
2	1	14
3	0	60
4	1	17
5	2	38
6	1	20
7	0	48
8	1	9
9	1	1
10	0	10

Table: Formato de datos

¿Como analizamos esta información?

Se debe tener en cuenta que algunas variables que implican tiempo, tienen una distribución particular; pensemos en el tiempo de estancia hospitalaria (Usualmente sesgada a la derecha) ¿por qué?

La censura limita el conocimiento preciso de cuando se presenta el evento de interés.

La función de supervivencia $S(t)$

debe tener unas particularidades intuitivas:

- que al empezar el estudio la supervivencia global sea del 100%
- si seguimos al individuo por "la infinidad" el evento se presentará.

Kaplan - Meier

Una forma tradicional de estimar $S(t)$ es por medio del estimador no paramétrico **Kaplan-Meier**.

Probabilidad

Bag model

Supongamos que en el momento del tiempo t_0 o en la bolsa t_o hay n canicas (individuos), de los cuales k son blancas(vivos) y j son rojas (muertes) y $k + j = n$. La probabilidad de obtener en ese momento una bola roja (una muerte) no es mas que;

$$P(roja) = \frac{j}{k+j} = \frac{j}{n}$$

para el caso contrario la probabilidad de no obtener ninguna bola roja(defunción) es;

$$1 - P(roja) = 1 - \frac{j}{n}$$

Ahora supongamos que para el periodo siguiente esas j bolas ya no están debido a que se han perdido o no se regresan a la bolsa y que i bolas de las k blancas se vuelven rojas con el lapso de tiempo por lo que hay $k - i$ blancas:

$$P(roja) = \frac{i}{k}$$

kaplan Meier

En el análisis de los fenómenos que hemos analizado en cada momento del tiempo existen diferentes individuos en riesgo, así para el periodo t_i hay n_i individuos en riesgo de presentar el evento y en dicha muestra se presentan d_i eventos por lo cual para ese periodo la probabilidad de ocurrencia es $\frac{d_i}{n_i}$, por el contrario de no ocurrencia es $1 - \frac{d_i}{n_i}$. así el estimador de **K.M.** se define como

$$\hat{S}(t_i) = \prod_{t \leq t_i} \left(1 - \frac{d_i}{n_i}\right)$$

id	meses	evento
1	3	1
2	4	0
3	5	1
4	4	1
5	3	0
6	5	1
7	6	0
8	7	1

Table: Fuente: Elaboración propia

tiempo	Sujetos riesgo	excluidos	P(a)	1-P(a)	K.M(t)
3	8	2	1/8	7/8	(7/8)
4	6	2	1/6	5/6	(7/8) (5/6)
5	4	2	1/2	1	(7/8) (5/6) (2/2)
6	2	1	0	1	1
7	1	1	1	0	0

Table: Estimador de kaplan Meier

La base organizada de manera adecuada

caso	estado	tiempo en meses
1	0	24
2	0	14
3	1	60
4	0	17
5	0	38
6	0	20
7	1	48
8	0	9
9	0	1
10	1	10

Table:)

Estimación

Para llevar a cabo la estimación de $S(t)$ por el estimador no paramétrico **K.M.** debemos organizar la variable de evento de tal forma que los datos **censurados** se codifiquen con el valor cero(**0**) y los no censurados con la unidad(**1**).

Para poder llevar el análisis, previamente a la obtención de $\hat{S}(t)$ debemos establecer o indicarle al programa cual es la variable de censura o no-censura y el tiempo de ocurrencia.

```
1 from lifelines import KaplanMeierFitter
2 import matplotlib.pyplot as plt
3 km = KaplanMeierFitter()
4 km.fit(durations=t_event['t'],
5       event_observed=t_event['event'])
6 km.plot()
7 plt.title('Curva de Kaplan-Meier (Default)')
8 plt.xlabel('D as')
9 plt.ylabel('Probabilidad de supervivencia')
10 plt.show()
```

Función estimada

posteriormente la función de supervivencia $\hat{S}(t)$ estimada por **K.M.** se obtiene por el comando

```
1 survival_function = km.survival_function_  
2 print(survival_function)
```

Por lo general nos interesa el percentil 50.

¿Que utilidad tiene esto?

La comparación de dos curvas de supervivencia en dos poblaciones homogéneas con una diferencia de exposición nos permite establecer comparaciones entre dos curvas.


- Existe diferencias en la supervivencia entre un grupo A y un grupo B.
- tienen mas supervivencia los individuos diagnosticado cáncer A o B.
- Es mas efectivo un tratamiento A o B para recuperar el movimiento.

log-rank test

Para probar que las curvas son iguales o que no existen diferencias significativas entre ellas partimos de la hipótesis nula H_0 de que ambas curvas son similares y no que tienen diferencias significativas entre ellas y utilizamos el comando:

```
1 from lifelines.statistics import
   multivariate_logrank_test
2 # H0: Todas las curvas de supervivencia son iguales
3 # H1: Al menos una curva es diferente
4 # Log-rank generalizado
5 res2 = multivariate_logrank_test(t_event["t"],
6 t_event["Quartil_value"], t_event["event"])
7 pval = res2.p_value
```


Presentación curva



Fuente: Base drugtr Stata

Laboratorios

- Laboratorio en R (**Click aquí**)
- Laboratorio en Python (**Click aquí**)

Hazard function

...

La probabilidad de que ocurra el evento en el momento t dado que no se ha presentado hasta ahora.

...

$$h(t) = \lim_{\Delta t \rightarrow 0} \frac{P(t \leq T < t + \Delta t \mid T \geq t)}{\Delta t} \quad (4)$$

Hazard rate

La función **hazard** $h(t)$ describe la probabilidad *instantánea* de que un evento ocurra en el momento t dado que no ha ocurrido antes.

$$h(t) = \frac{f(t)}{1 - F(t)} = \frac{f(t)}{S(t)} \quad (5)$$

La función hazard me dice dado que el crédito aun sigue vivo en el periodo t , que tan probable es que haga default ahora mismo.

....
 $h(30)$ Probabilidad de que se presente el default hoy dado que ha sobrevivido los primeros 29 días.

...
Una aplicación práctica es que nos permite conocer el momento con mayor riesgo de presentar el evento, por lo que nos da a conocer el mejor momento para intervenir.

Función de riesgo acumulada

Definición

$$H(t) = \int_0^t h(u) du \quad (6)$$

En términos intuitivos mide todo el riesgo experimentado hasta (t) .

está relacionada con la función de supervivencia:

...

$$S(t) = e^{-H(t)} \quad (7)$$

...

$$H(t) = -\ln S(t) \quad (8)$$

Estimador de Nelson - Aalen

Es un estimador no paramétrico de la función de riesgo acumulada.

$$\hat{H}(t) = \sum_{t_i \leq t} \frac{d_i}{n_i} \quad (9)$$

- t_i tiempo en el que ocurre al menos una mora.
- d_i representa número de eventos (moras, fallos, muertes) etc, en el tiempo t_i .
- n_i número de individuos en riesgo antes de t_i .

Convergente asintóticamente con la supervivencia, dada la relación expresada anteriormente.

...

La función de hazard acumulada mide cuanta presión total de riesgo ha soportado la cartera desde el inicio hasta t .

...

Si $H(t)$ es grande entonces la cartera ha estado expuesta a muchos momentos de riesgo!.

Nelson-Aalen con python

```
1 from lifelines import NelsonAalenFitter
2 import matplotlib.pyplot as plt
3 naf = NelsonAalenFitter()
4 naf.fit(durations=t_event["t"], event_observed=t_event
        ["event"])
5 # Plot de hazard acumulada
6 plt.figure(figsize=(8,5))
7 naf.plot()
8 plt.title("Hazard Acumulada ( Nelson Aalen )")
9 plt.xlabel("Tiempo")
10 plt.ylabel("H(t)")
11 plt.grid(True)
12 plt.show()
```

El hazard desde el acumulado

```
1 def hazard_lifelines(df):
2     from lifelines import NelsonAalenFitter
3     naf = NelsonAalenFitter().fit(df["t"], df["event "
4         ])
5     H = naf.cumulative_hazard_
6     h = H.diff().fillna(H)
7     h.columns = ["hazard"]
8     return H, h
9
10 H, h = hazard_lifelines(t_event)
11
12 h.sort_values('hazard', ascending=False).head() # los
13     d as puntuales con mayor riesgo de presentar
14     default..
```

Toma de decisiones

tanto en **origen** como en **cobranza** la información de supervivencia nos ayuda a tomar decisiones como por ejemplo; conocer con exactitud el tiempo más oportuno y para darnos ideas de si necesitamos segmentar el modelo de origen o incluir interacciones en las variables.

Regla operativa

...

Priorizar clientes con


$$S(t) \times h(t) \text{ alto} \quad (10)$$

esto significa clientes vivos con el mayor riesgo!

...

- Clientes con $S(t)$ alta y $h(t)$ creciente $\rightarrow$ intervención leve (recordatorio).
- Clientes con $S(t)$ baja y $h(t)$ pico $\rightarrow$ oferta de reestructuración agresiva (salvamento).
- Clientes con $S(t)$ extremadamente baja y $h(t)$ muy bajo $\rightarrow$ asignar a cobranzas legales (recuperación).

Evaluación de campañas


$$lift = \frac{h_{tratados}(t)}{h_{controles}(t)} \quad (11)$$

Modelo de origen

Puede ser necesario segmentar porque la relación entre las variables explicativas (features) y el evento de interés (mora, default, muerte, etc..) puede ser diferente en cada segmento. Si por ejemplo hacemos una regresión logística los coeficientes se promediaran y por lo tanto se pueden sesgar.

Ejemplo

Tenemos el cliente **A** y el cliente **B**; en **A** el default puede ser tardío y poco, mientras en **B** el default puede ser temprano y registrar muchos más eventos, cuando se entra el modelo sobre ambos, entonces:

- Los coeficientes se promedian
- Variables predictoras en **A** pero no **B**.
- las políticas de origen pueden distorsinarse.
- rechaza clientes buenos en **A** y aprueba malos en **B**.

Segmentar no es para alimentar el modelo, es para que el modelo aprenda de forma más limpia las relaciones de las variables.

Posible ruta

- Aplicar test para observar si existen diferentes curvas por producto por ejemplo.
- Si se identifica un patrón de diferencia podría ser necesario segmentar.
- Evaluar modelo sin segmentar contra modelos segmentados.
- Comparar la gancia de la segmentación y la complejidad operacional.

life time value

Valor de vida del cliente,

Valor de vida del cliente

La cantidad de ingresos que esperamos percibir de un cliente mientras está en la empresa.

No queremos maximizar solo métricas si no el valor de vida del cliente,